

Bases de données orientées graphes

Antoine Berthion

20 Août 2025

1 Introduction

Les bases de données orientées graphes constituent une approche alternative aux modèles classiques (relationnels, documents, colonnes). Elles reposent sur la théorie des graphes, ce qui les rend particulièrement adaptées pour représenter des ensembles d'entités fortement interconnectées. Dans ce document, nous présentons une formalisation mathématique de leur fonctionnement.

2 Modèle mathématique

Un graphe orienté est défini comme un couple :

$$G = (V, E) \tag{1}$$

où V est un ensemble fini de sommets et $E \subseteq V \times V$ est un ensemble d'arêtes orientées (que l'on peut voir comme des *relations*).

2.1 Attributs

Afin de stocker des informations supplémentaires, on introduit deux fonctions d'attributs :

$$\phi_V : V \rightarrow \mathcal{A}_V \tag{2}$$

$$\phi_E : E \rightarrow \mathcal{A}_E \tag{3}$$

où $\mathcal{A}_V$ et $\mathcal{A}_E$ désignent respectivement les ensembles des attributs possibles pour les sommets et les arêtes. Intuitivement, on peut lier cette notation à la notion de tables à multiples entrées dans les bases de données classiques. Un tel modèle est appelé *graphe à propriétés*.

3 Opérations fondamentales

Une requête sur une base graphe correspond à une opération sur les ensembles V et E . Nous allons énumérer et formaliser quelques opérations et éléments relatifs à la technologie des bases de données en graphe.

3.1 Voisinage

Le voisinage sortant d'un sommet $v \in V$ est défini par :

$$\Gamma(v) = \{u \in V \mid (v, u) \in E\}. \quad (4)$$

3.2 Chemins

Un chemin de longueur k est une suite $(v_0, v_1, \dots, v_k)$ telle que $(v_i, v_{i+1}) \in E$ pour tout $i < k$. On note E^k l'ensemble des couples de sommets reliés par un chemin de longueur k .

3.3 Plus court chemin

Si chaque arête $e \in E$ est pondérée par un poids $w(e) \geq 0$, le problème du plus court chemin entre s et t consiste à trouver :

$$\min_{\substack{(v_0, \dots, v_k) \\ v_0=s, v_k=t}} \sum_{i=0}^{k-1} w(v_i, v_{i+1}). \quad (5)$$

4 Comparaison avec le modèle relationnel

Dans le modèle relationnel, les données sont représentées par des tables, i.e. des sous-ensembles d'un produit cartésien. Une relation entre entités nécessite alors une jointure. Dans un graphe, les relations sont directement matérialisées par les arêtes, ce qui rend l'exploration des liens plus naturelle et plus efficace.

5 Complexité algorithmique

L'efficacité des bases de données en graphe découle directement de la complexité algorithmique des opérations fondamentales.

- Le calcul du voisinage $\Gamma(v)$ s'effectue en temps $O(\deg^+(v))$, où $\deg^+(v)$ est le degré sortant du sommet v .
- Une exploration en largeur (BFS) de tout le graphe s'effectue en $O(|V| + |E|)$, ce qui permet de parcourir l'ensemble des relations efficacement.
- Le calcul du plus court chemin (algorithme de Dijkstra) se fait en $O(|E| + |V| \log |V|)$ si les arêtes sont pondérées.

Ces résultats montrent que la modélisation par graphes est adaptée aux problèmes de connectivité, mais moins aux opérations globales de type agrégation massive, qui restent plus naturelles dans le modèle relationnel.

6 Exemple formel

Considérons l'ensemble des sommets :


$$V = \{\text{Antoine}, \text{Andrius}, \text{Natty}, \text{Capucine}\}, \quad (6)$$

et les arêtes (relations) :

$$E = \{(\text{Antoine}, \text{Andrius}), (\text{Andrius}, \text{Natty}), (\text{Natty}, \text{Capucine})\}. \quad (7)$$

Nous noterons qu'Antoine et Andrius sont les meilleurs amis du monde. Alors, le voisinage d'ordre 2 de Antoine est :

$$\Gamma^2(\text{Antoine}) = \{u \in V \mid \exists v \in V, (\text{Antoine}, v) \in E \wedge (v, u) \in E\} = \{\text{Natty}\}. \quad (8)$$



7 Outils et systèmes concrets

7.1 Neo4j

Neo4j est le système de gestion de bases de données orientées graphes le plus répandu. Il implémente directement le modèle des *graphes à propriétés* défini plus haut : chaque nœud et chaque arête possède un ensemble d'attributs (ϕ_V, ϕ_E) , et les requêtes se font via le langage **Cypher**. Celui-ci permet d'exprimer des motifs de la forme

$$(v_1) - [e] \rightarrow (v_2),$$

qui correspondent exactement aux couples $(v_1, v_2) \in E$. Plus simplement, il s'agit de trouver un chemin où il existe un sommet (v_1) , relié par une arête e à un sommet (v_2) . En pratique, la recherche de voisins d'ordre k ou de plus courts chemins est optimisée grâce à des index internes et des **BFS**.

7.2 ArangoDB

ArangoDB est un système multi-modèle, capable de gérer à la fois des documents, des paires clé-valeur et des graphes. Dans son modèle graphe, il suit également la logique (V, E) , mais les sommets sont stockés sous forme de documents JSON et les arêtes comme collections spécialisées. Les requêtes s'expriment en AQL (*Arango Query Language*), qui autorise la navigation dans les graphes avec des expressions du type :

$$\text{FOR } v, e, p \text{ IN } 1..k \text{ OUTBOUND } s \text{ GRAPH } G \text{ RETURN } v.$$

Cette syntaxe correspond directement au voisinage $\Gamma^k(s)$ défini mathématiquement dans l'équation 4.

7.3 Remarque

Ces outils montrent que la théorie des graphes n'est pas un simple formalisme abstrait, mais la base opérationnelle de systèmes largement utilisés dans l'industrie (réseaux sociaux, bio-informatique, analyse de dépendances, etc.).

8 Extensions et généralisations

Le modèle des graphes orientés peut être enrichi de plusieurs manières :

- **Graphes non orientés** : où les arêtes sont des ensembles non ordonnés $\{u, v\}$, utiles pour représenter des relations symétriques (par exemple, la co-appartenance à un groupe).
- **Hypergraphes** : où une arête peut relier plus de deux sommets, ce qui généralise la notion de relation à n -uplets.
- **Graphes étiquetés** : où chaque arête possède un type, permettant de distinguer les différentes natures de relations dans le même graphe.

9 Conclusion

Les bases de données orientées graphes trouvent leur fondement dans la théorie des graphes. Elles permettent de modéliser les données et leurs relations de manière naturelle, et facilitent les requêtes exploitant la connectivité. Grâce à leur formalisme mathématique, elles constituent un pont élégant entre théorie des graphes et informatique appliquée.